logo-mba.png

Custo do erro silencioso em pipelines analíticos: onde posicionar a validação de dados

Gisele Fonseca de Aguiar Silva[1]*; **[PENDENTE: Nome do Especialista de Business Case]**[2]

[1]Mestra em Administração. Engenheira de dados. E-mail do autor correspondente: gih52sim@gmail.com
[2]**[PENDENTE: Titulação do Especialista]**. **[PENDENTE: Instituição]**. E-mail: **[PENDENTE: e-mail]**

Custo do erro silencioso em pipelines analíticos: onde posicionar a validação de dados

Sumário Executivo

[PENDENTE: redigir ao final, quando os resultados estiverem fechados — 250 palavras, parágrafo único, pretérito perfeito, sem citações. Rascunho provisório abaixo, a revisar.] Pipelines analíticos entregaram métricas incorretas sem gerar qualquer alarme quando o código de transformação continha defeito semântico, isto é, lógica que executou normalmente mas não correspondeu à intenção de negócio. O estudo examinou esse problema no contexto de equipes de engenharia de dados que mantêm transformações que não escreveram. Construiu-se um experimento de injeção de defeitos sobre um pipeline analítico com dados simulados gerados a partir de procedimentos estatísticos declarados, no qual nove mecanismos de defeito, ancorados em taxonomia publicada, foram confrontados com quatro camadas de controle de qualidade de dados, medindo-se o erro induzido em sete métricas de negócio ao longo de trinta repetições. **[PENDENTE: complementar com a segunda frente (levantamento de projetos públicos) e com os resultados finais.]** Os testes de schema e os testes genéricos de unicidade, nulidade e integridade referencial não detectaram nenhum dos nove defeitos, por verificarem a forma da tabela e não o significado do número. A reconciliação de contagem de linhas reduziu a exposição de forma expressiva, mas permaneceu cega aos defeitos que preservam a contagem, um dos quais produziu erro superior a sessenta por cento no faturamento apurado. O estudo entregou uma matriz de alocação de controles, indicando qual verificação posicionar em cada camada conforme o mecanismo de defeito e as métricas consumidas pelo negócio, com o risco residual de cada configuração dimensionado em valor financeiro.

Introdução

[PENDENTE: Parte (i) — problema ou oportunidade. Fórmula sugerida pelo material do curso: "o problema de A tem o efeito de B, com o impacto de C". Aqui: código de transformação que não foi escrito por quem o mantém produz erro semântico que executa em silêncio (A), a métrica entregue ao negócio sai errada sem alarme (B), e a decisão tomada sobre ela carrega exposição financeira não medida (C).]

[PENDENTE: Parte (ii) — contexto. Engenharia de dados em ambiente de setor financeiro; a prática corrente de validação apoiada em testes genéricos e de schema; e a literatura recente sobre falha silenciosa em SQL gerado por modelos de linguagem, que documenta a taxa de erro semântico mas avalia a consulta isolada, e não o dano à métrica quando a consulta vira modelo de transformação em produção.]

[PENDENTE: Parte (iii) — objetivo, no último parágrafo, único, claro, específico e mensurável. Dizer o que se vai MEDIR, não "analisar" nem "compreender". Rascunho: "O objetivo deste trabalho foi quantificar o erro induzido em métricas de negócio por mecanismos de defeito semântico em modelos de transformação de dados e determinar a capacidade de detecção de cada camada de controle de qualidade, estabelecendo uma matriz de alocação de controles com o risco residual de cada configuração expresso em valor financeiro."]

Desenvolvimento

Caracterização do Objeto de Estudo

O objeto deste estudo é a camada de transformação de pipelines analíticos e o conjunto de controles de qualidade que a cerca. Entende-se por camada de transformação o código que converte dados brutos ingeridos de sistemas de origem em tabelas agregadas, consumidas por relatórios e indicadores de negócio. Em arquiteturas correntes essa camada é escrita predominantemente em “Structured Query Language” [SQL] e organizada em modelos versionados, executados em cadeia por um orquestrador.

O ambiente de referência é o de equipes de engenharia de dados que operam pipelines em produção no setor financeiro, no qual indicadores derivados alimentam decisões de crédito, exposição e prestação de contas regulatória. Três características desse ambiente delimitam o problema tratado. A primeira é a separação entre quem escreveu a transformação e quem a mantém: parte relevante da lógica em operação foi construída por equipes anteriores e é sustentada por profissionais que não participaram da sua concepção. A segunda é a tolerância a falhas adotada por projeto, em que conversões e junções são deliberadamente permissivas para que a execução não interrompa em presença de dado inesperado. A terceira é a assimetria entre a velocidade de produção de código de transformação e a velocidade de produção de verificação, acentuada pela adoção de assistentes de geração de código.

As partes interessadas são a equipe de engenharia de dados, responsável pela construção e manutenção dos modelos; as áreas de negócio, que consomem os indicadores sem acesso à lógica que os produz; e as funções de controle interno e auditoria, que respondem pela fidedignidade dos números reportados. A assimetria de informação entre esses grupos é o que torna a falha silenciosa relevante: o consumidor do indicador não dispõe de meio próprio para questioná-lo.

Diagnóstico do Problema

O defeito tratado neste estudo não é a interrupção do pipeline, e sim a sua conclusão bem-sucedida com resultado incorreto. Um modelo de transformação com defeito semântico é aquele cuja consulta é sintaticamente válida, executa sem exceção e materializa a tabela de destino, mas não corresponde à intenção de negócio que deveria implementar. A literatura da área de geração automática de consultas denomina essa classe de ocorrência falha silenciosa, por oposição à falha ruidosa, que interrompe a execução e é, por isso, barata de detectar.

A magnitude do fenômeno está documentada para consultas geradas por modelos de linguagem. Erros de natureza semântica respondem por parcela expressiva do total de erros observados em conjuntos de avaliação consagrados, e a maior parte deles decorre de má interpretação do esquema do banco ou da pergunta formulada, e não de erro de sintaxe **[PENDENTE: inserir citações autor-ano após confirmar as autorias completas nas fontes originais]**. Trabalhos recentes de verificação relatam, ainda, que a autoavaliação do próprio modelo gerador tende à confiança excessiva, com baixa revocação na identificação dos seus

erros, o que inviabiliza delegar a verificação ao mesmo mecanismo que produziu o código.

Dois limites dessa literatura delimitam a lacuna aqui tratada. O primeiro é de objeto: a avaliação recai sobre a consulta isolada, em tarefa de pergunta e resposta, e não sobre o modelo de transformação em operação, cujo resultado incorreto é materializado em tabela e consumido por um indicador. O segundo é de desfecho: mede-se a correção da consulta, e não o dano causado à métrica de negócio. Em paralelo, a literatura de qualidade de pipelines de dados oferece taxonomia empiricamente fundamentada de fatores de influência e causas-raiz, mas não quantifica o custo de detectar a falha em cada camada, conforme declarado pelos próprios autores (Foidl et al., 2024).

A restrição prática que sustenta a relevância da intervenção é a natureza dos controles usualmente adotados. Os testes de uso corrente verificam propriedades da forma da tabela, como unicidade da chave, ausência de nulos, integridade referencial e conformidade de tipos. Defeito semântico, por definição, preserva a forma: a tabela resultante continua tendo chave única, colunas não nulas e referências válidas, ainda que os valores estejam errados. Decorre daí a hipótese que o estudo submete a teste: a pilha de controles de maior penetração na prática é estruturalmente incapaz de detectar a classe de defeito que mais cresce em frequência.

Procedimentos Metodológicos

O estudo é de natureza aplicada e abordagem quantitativa, e combina dois delineamentos complementares. O primeiro é um experimento controlado de injeção de defeitos, conduzido sobre um pipeline analítico com verdade conhecida por construção, no qual se manipula o mecanismo de defeito e se observa, simultaneamente, o erro induzido em cada métrica de negócio e a detecção obtida por cada camada de controle. O segundo é um levantamento de caráter exploratório sobre projetos públicos de transformação de dados, destinado a estabelecer quais camadas de controle são efetivamente declaradas na prática.

A articulação entre os dois delineamentos é o que permite responder à pergunta de gestão. O experimento estabelece o que cada camada de controle detecta; o levantamento estabelece quais camadas as equipes de fato adotam. O cruzamento dos dois resultados fornece a exposição associada à configuração de controles mais frequente, que é o insumo da decisão de alocação.

A opção por dados simulados no experimento decorre de exigência do próprio desenho: a mensuração do erro induzido pressupõe conhecer o valor correto da métrica, o que inexiste em base operacional. As normas institucionais admitem a geração de dados simulados para os Business Cases de Engenharia de Software, condicionada à fundamentação em procedimentos estatísticos bem definidos e à sua descrição detalhada, requisito atendido na subseção seguinte. Nenhum dado de organização privada foi utilizado em qualquer das duas frentes.

Geração dos Dados Simulados

O cenário simulado reproduz um domínio de pedidos e itens de pedido, com 100 contas de cliente, 30.000 pedidos e janela de observação de 90 dias. A métrica central é o faturamento

líquido do período, obtida pela soma, sobre os pedidos não cancelados, do produto entre quantidade, preço unitário e complemento do desconto. Os procedimentos estatísticos de geração estão na Tabela 1.

Tabela 1. Procedimentos estatísticos de geração do cenário simulado

Elemento	**Procedimento**
Porte da conta	Lognormal($\mu = 0$; $\sigma = 0,8$), normalizado pela média
Alocação de pedidos	Multinomial com probabilidade proporcional ao porte
Itens por pedido	$1+$ Poisson($\lambda = 2$)
Quantidade por item	$1+$ Poisson($\lambda = 1$)
Preço unitário	Lognormal($\mu = 3,2$; $\sigma = 0,7$) escalado pelo porte
Desconto	Uniforme discreta sobre $\{0; 0,05; 0,10; 0,15\}$
Status do pedido	Multinomial (cancelado 0,08; pendente 0,07; concluído 0,85)
Status ausente	Bernoulli, $p = 0,030\,(1 + 0,90z)$, z truncado em $[-1; 3]$
Duplicação de item	Bernoulli($p = 0,02$)
Pedido sem item	Bernoulli($p = 0,03$)

Fonte: Resultados originais do estudo

Nota: z é o valor padronizado do pedido. A probabilidade crescente de status ausente com o valor do pedido reproduz falha correlacionada ao valor, em que o defeito atinge preferencialmente os registros de maior magnitude.

Quatro complicações foram deliberadamente embutidas nos dados de origem, de modo que o cenário apresentasse as ambiguidades que um modelo de transformação precisa resolver corretamente. A primeira é a ausência de status em parte dos pedidos, decorrente de lacuna de ingestão, com probabilidade crescente conforme o valor do pedido; trata-se de falha correlacionada ao valor, que atinge preferencialmente os registros de maior magnitude. A segunda é a duplicação de linhas de item por dupla carga da origem, que exige deduplicação a jusante. A terceira é a existência de pedidos válidos sem nenhum item, cuja receita é legitimamente nula. A quarta é a defasagem entre a data do pedido e a data de embarque, que cria a possibilidade de filtragem pela coluna errada.

Validação do Instrumento

Antes de qualquer injeção de defeito, verificou-se que o instrumento media o que se propunha a medir. Para tanto, a verdade do cenário foi calculada diretamente a partir do processo gerador, sem passar por consulta, e comparada ao resultado de uma implementação de referência em SQL. As duas apurações coincidiram nas sete métricas observadas, com diferença relativa nula até a sexta casa decimal. Essa conferência é condição de validade interna do experimento: sem ela, qualquer erro atribuído a um defeito injetado poderia ser, na verdade, erro do próprio aparato de medição.

Mecanismos de Defeito Injetados

Foram implementados nove mecanismos de defeito, cada um correspondendo a uma classe documentada na literatura de erros em consultas geradas e em qualidade de pipelines, de modo que o catálogo não resultasse de escolha arbitrária do pesquisador. Todos foram implementados como consultas executáveis sobre as mesmas tabelas de origem, e todos produzem tabela de destino sem levantar exceção. A Tabela 2 descreve os mecanismos.

Tabela 2. Mecanismos de defeito semântico injetados no modelo de transformação

Cód.	Defeito injetado	Classe na taxonomia
D1	Junção de pedidos a itens com soma do total do cabeçalho	Erro de grão, com multiplicação do valor pelo número de itens
D2	Junção interna no lugar de junção externa à esquerda	Erro de síntese, com descarte de pedidos sem item
D3	Comparação de desigualdade sobre coluna que admite nulo	Má interpretação do banco, pela lógica de três valores
D4	Literal de filtro grafado em caixa divergente da origem	Valor de filtro fabricado, que torna o filtro inoperante
D5	Filtragem pela data de embarque no lugar da data do pedido	Má interpretação do esquema
D6	Omissão da deduplicação da dupla carga de itens	Omissão de etapa de limpeza
D7	Desconsideração do percentual de desconto	Semântica de coluna incorreta
D8	Produto entre preço máximo e quantidade somada do pedido	Erro de grão aritmético em pedido com vários itens
D9	Intervalo fechado sobre carimbo de tempo	Erro de fronteira, que exclui o último dia da janela

Fonte: Resultados originais do estudo

Nota: A classificação apoia-se nas taxonomias de erro semântico em consultas geradas e de causas-raiz em pipelines de dados **[PENDENTE: citar autor-ano após confirmar autorias]**. Nenhum dos nove mecanismos interrompe a execução.

Camadas de Controle Avaliadas

Cada modelo defeituoso foi submetido a quatro camadas de controle, dispostas em ordem crescente de custo de implantação, descritas na Tabela 3. A escolha das camadas reproduz a prática corrente: testes de forma e de esquema são os de menor custo e maior penetração, ao passo que a reconciliação de valor exige a existência de um total de controle independente na origem, nem sempre disponível.

Métricas de Negócio Observadas

Para cada execução registrou-se o erro relativo induzido em sete métricas, escolhidas por representarem usos distintos do mesmo conjunto de dados: a soma do faturamento, a média e a mediana do valor por pedido, o percentil 95 da distribuição de valores, a contagem de pedidos,

Tabela 3. Camadas de controle de qualidade avaliadas e respectivos critérios de disparo

Cód.	Camada	Critério de disparo
C1	Reconciliação de contagem	Divergência superior a 0,1% entre a contagem de pedidos no destino e a contagem apurada independentemente na origem
C2	Testes genéricos de forma	Violação de unicidade da chave, de ausência de nulos na chave ou na medida, de integridade referencial ou de não negatividade
C3	Esquema e contrato	Ausência de coluna esperada ou divergência de tipo na medida
C4	Reconciliação de valor	Desvio superior a 5% entre a razão do total do destino pelo total declarado na origem e a razão calibrada em período saudável

Fonte: Resultados originais do estudo

Nota: O total declarado na origem não é oráculo: inclui imposto e frete, que o modelo analítico exclui por definição. Por isso a reconciliação de valor opera por razão calibrada com banda de tolerância, e não por igualdade. A banda de 5% é parâmetro de projeto, não medida de campo; a sensibilidade do resultado a esse valor foi avaliada e consta da Discussão dos Resultados.

o valor máximo observado e a soma da conta de maior faturamento. A inclusão de métricas de cauda e de concentração justifica-se por serem as que alimentam decisões de exposição e limite, e por serem as menos cobertas pelos controles de uso corrente.

Cada combinação de mecanismo de defeito foi executada sob 30 sementes aleatórias distintas, totalizando 270 execuções, e os resultados são reportados como média e desvio-padrão entre repetições. A repetição responde a uma limitação de desenhos com semente única, nos quais um valor nulo de erro pode decorrer de sorteio favorável e não de ausência de efeito.

Levantamento de Projetos Públicos de Transformação

A segunda frente destina-se a estabelecer quais camadas de controle são efetivamente declaradas em projetos reais. A população de interesse é a dos repositórios públicos que contêm projeto de transformação de dados, e o quadro amostral foi construído por busca de código sobre o arquivo de configuração que caracteriza esse tipo de projeto. Como o serviço de busca limita o número de resultados por consulta, o quadro foi montado por estratificação em nove faixas de tamanho de repositório, procedimento que supera esse limite sem recorrer a amostragem por conveniência.

Aplicaram-se cinco critérios de exclusão, nesta ordem, com registro da contagem por critério: repositório derivado de outro, por não representar decisão própria de teste; repositório arquivado, por não refletir prática corrente; ausência de diretório de modelos; projeto com menos de cinco modelos, por caracterizar exercício; e indício de material didático no nome ou na descrição. A amostragem é aleatória simples sem reposição sobre o quadro elegível, com semente fixa, de modo a permitir replicação.

A mensuração consiste na leitura dos arquivos de declaração de testes de cada projeto e na contagem, por tipo, dos testes efetivamente declarados, incluindo os contratos de esquema e os pacotes de teste adotados. Cada projeto é então classificado na camada mais alta que possui, segundo o mapeamento da Tabela 4, que é o que torna as duas frentes comparáveis.

Tabela 4. Correspondência entre camada de controle e teste observável em projeto real

Cód.	Camada	Declaração observável no projeto
C1	Reconciliação de contagem	Testes de igualdade e de limite de contagem de linhas entre relações; testes de anomalia de volume
C2	Testes genéricos de forma	Testes nativos de unicidade, ausência de nulos, valores aceitos e integridade referencial
C3	Esquema e contrato	Contrato de modelo com imposição ativa, restrições de coluna e testes de conformidade de tipo
C4	Reconciliação de valor	Pacotes de comparação entre relações; testes de expressão sobre agregados; testes singulares com indício de reconciliação

Fonte: Resultados originais do estudo

Nota: A identificação de reconciliação em teste singular é heurística, baseada em padrões textuais, e superestima a camada C4. O valor obtido para essa camada deve ser lido como limite superior.

O instrumento de leitura foi aferido por dois procedimentos antes da coleta. O primeiro consistiu em submetê-lo a casos construídos com gabarito conhecido, cobrindo os formatos de declaração em uso, inclusive a renomeação recente da chave de declaração de testes, que um leitor ingênuo desconsideraria por completo. O segundo consistiu na conferência contra arquivos de declaração de projetos reais, com comparação manual do resultado. **[PENDENTE: reportar a execução da coleta e o número de projetos efetivamente analisados quando a frente for concluída.]**

Discussão dos Resultados

Detecção por Camada de Controle

[PENDENTE: Tabela da matriz defeito × controle. Resultado central: os testes genéricos e o teste de schema não detectaram nenhum dos nove defeitos.]

Risco Residual por Pilha de Controles

[PENDENTE: Tabela das pilhas A a D com exposição somada. Discutir que adotar testes genéricos sobre nada não reduziu exposição, que a reconciliação de contagem teve o melhor retorno, e que o restante só cai com reconciliação de valor.]

Vulnerabilidade Dependente da Métrica

[PENDENTE: Discutir o defeito invisível no faturamento e material na mediana, e a cauda como pior caso.]

Viabilidade da Proposta

[PENDENTE: Quatro fatores: operacional (funciona na prática), financeira (faz sentido econômico), estratégica (alinhada à visão da organização) e social (impacto sobre as pessoas). Separar ganhos tangíveis de intangíveis.]

Considerações Finais

[PENDENTE: Contribuições práticas, valor gerado e perspectivas futuras. Sem citações, sem reapresentar dados.]

Referências

FOIDL, H.; GOLENDUKHINA, V.; RAMLER, R.; FELDERER, M. Data pipeline quality: influencing factors, root causes of data-related issues, and processing problem areas for developers. **Journal of Systems and Software**, v. 207, 111855, 2024.

[PENDENTE: demais referências — conferir cada uma contra os modelos do item 21 do manual, que distingue periódicos, relatórios de dados online, livros, trabalhos acadêmicos, documentos jurídicos e anais.]